تسک مشترک ۱: منشأ داده و سازوکار جمع‌آوری

منبع رسمی داده: داده‌های این پروژه از پیمایش ملی بررسی سلامت و تغذیه آمریکا (NHANES) است که توسط CDC/NCHS اجرا و منتشر می‌شود.

دوره جمع‌آوری: داده‌ها مربوط به اوت ۲۰۲۱ تا اوت ۲۰۲۳ است که نخستین انتشار ملی این پیمایش پس از وقفه ناشی از همه‌گیری کرونا محسوب می‌شود.

نوع مطالعه و روش کلی تولید داده: این داده حاصل یک پیمایش و مطالعه مشاهده‌ای مقطعی است (آزمایش تصادفی نیست). داده‌ها از طریق ترکیب مصاحبه‌های جمعیت‌شناختی (DEMO_L)، معاینات فیزیکی و تصویربرداری الاستوگرافی کبد در مراکز معاینه سیار (LUX_L، BMX_L، BPXO_L) و آزمایش‌های خون و بیوشیمی (CBC_L، GHB_L، TCHOL_L، BIOPRO_L) تولید شده‌اند.

محدودیت دسترسی: تمامی فایل‌ها از بخش عمومی وب‌سایت رسمی CDC (Public Data Files) با فرمت استاندارد XPT. دریافت شده‌اند و هیچ‌گونه محدودیت دسترسی وجود ندارد.

تسک مشترک ۲: واحد مشاهده و ساختار داده

واحد مشاهده: هر ردیف در مجموعه داده تحلیلی نهایی نماینده یک فرد شرکت‌کننده مستقل در پیمایش است که با شناسه یکتای SEQN مشخص می‌شود.

ساختار داده و عدم تکرار: داده‌های دوره ۲۰۲۱ تا ۲۰۲۳ پیمایش NHANES به صورت مقطعی گردآوری شده‌اند؛ بنابراین برای هر فرد در هر فایل حداکثر یک ردیف وجود دارد و مشاهده تکراری در طول زمان ثبت نشده است.

ساختار ارتباط فایل‌ها: متغیرهای مورد استفاده در ۸ فایل موضوعی جداگانه قرار دارند که همگی از طریق شناسه مشترک SEQN با رابطه یک‌به‌یک به یکدیگر متصل می‌شوند. ساختار سلسله‌مراتبی یا تکرارشونده وجود ندارد.

تسک مشترک ۳: نمونه‌گیری، انتخاب و قابلیت تعمیم (الزام الف ۲)

روش انتخاب افراد و نوع نمونه‌گیری: شرکت‌کنندگان در پیمایش NHANES به صورت داوطلبانه یا نمونه‌گیری تصادفی ساده انتخاب نشده‌اند، بلکه از طریق یک طرح نمونه‌گیری احتمالی پیچیده، چندمرحله‌ای و طبقه‌بندی‌شده از جمعیت غیرسازمانی ایالات متحده انتخاب شده‌اند.

نوع مطالعه: این پژوهش یک مطالعه مشاهده‌ای مقطعی است (آزمایش تصادفی نیست) و پژوهشگر هیچ مداخله‌ای روی شرکت‌کنندگان انجام نداده، بلکه صرفاً وضعیت موجود آن‌ها را اندازه‌گیری کرده

است.

شناسایی وزن و طرح نمونه‌گیری (الزام الف ۳): از آنجا که متغیرهای اصلی این پژوهش (الاستوگرافی کبد و آزمایش خون) در مراکز معاینه سیار (MEC) اندازه‌گیری شده‌اند، متغیر وزن مناسب برای تحلیل، وزن دوساله معاینات پزشکی یعنی WTMEC2YR است. در NHANES هر فرد نماینده تعداد متفاوتی از افراد جامعه است که به سه دلیل اصلی رخ می‌دهد: بیش‌نمونه‌گیری هدفمند: برخی زیرگروه‌ها (مانند سالمندان یا اقلیت‌های نژادی) با احتمال بیشتری وارد نمونه می‌شوند تا دقت برآورد در آن‌ها افزایش یابد. تعدیل عدم پاسخ‌دهی: وزن افراد شرکت‌کننده برای جبران غیبت افراد مشابهی که در معاینات حاضر نشده‌اند تنظیم می‌شود. پس‌طبقه‌بندی : وزن‌ها تنظیم می‌شوند تا مجموع آن‌ها با آمار سرشماری کل جمعیت غیرسازمانی ایالات متحده مطابقت داشته باشد.

قابلیت تعمیم به جمعیت بزرگ‌تر: در این پیمایش، به هر شرکت‌کننده یک «وزن نمونه‌گیری» (متغیر WTMEC2YR) اختصاص داده شده که نشان می‌دهد آن فرد نماینده‌ی چه تعداد از افراد در کل جامعه است. به همین دلیل، در صورت استفاده از این وزن‌ها می‌توان نتایج را به کل جمعیت بزرگسالان ۲۰ سال و بالاتر در ایالات متحده تعمیم داد؛ اما بدون اعمال وزن، نتایج صرفاً وضعیت افراد موجود در همین فایل داده را توصیف می‌کند.

تسک مشترک ۴: طبقه‌بندی متغیرها

مشخصات متغیرهای اصلی انتخاب‌شده از ۸ فایل داده به همراه نقش تحلیلی، نوع متغیر و مقیاس اندازه‌گیری آن‌ها در جدول زیر خلاصه شده است:

نام متغیر	فایل منبع	شرح متغیر	نقش در تحلیل	نوع متغیر	مقیاس اندازه‌گیری
SEQN	مشترک	شناسه یکتای شرکت‌کننده	کلید اتصال فایل‌ها	شناسه‌ای	اسمی
LUXSMED	LUX_L	میانه سفتی کبد (kPa)	متغیر پاسخ اصلی	کمی پیوسته	نسبی
NLR	محاسباتی (CBC_L)	نسبت نوتروفیل به لنفوسیت	متغیر توضیحی اصلی	کمی پیوسته	نسبی
LBDNENO	CBC_L	شمارش مطلق نوتروفیل	مؤلفه محاسبه NLR	کمی پیوسته	نسبی
LBDLYMNO	CBC_L	شمارش مطلق لنفوسیت	مؤلفه محاسبه NLR	کمی پیوسته	نسبی
LUXCAPM	LUX_L	میانه شاخص چربی کبد (CAP)	متغیر کنترلی	کمی پیوسته	نسبی
RIDAGEYR	DEMO_L	سن به سال کامل	فیلتر جمعیت و کنترل	کمی گسسته	نسبی
RIAGENDR	DEMO_L	جنسیت (مرد / زن)	متغیر گروه‌بندی	طبقه‌ای دودویی	اسمی

نام متغیر	فایل منبع	شرح متغیر	نقش در تحلیل	نوع متغیر	مقیاس اندازه‌گیری
BMXBMI	BMX_L	شاخص توده بدنی (BMI)	متغیر کنترلی	کمی پیوسته	نسبی
BPXOSY1	BPXO_L	فشار خون سیستولیک	متغیر کنترلی	کمی پیوسته	نسبی
LBXGH	GHB_L	قند خون سه‌ماهه (HbA1c)	متغیر کنترلی	کمی پیوسته	نسبی
LBXTC	TCHOL_L	کلسترول تام خون	متغیر کنترلی	کمی پیوسته	نسبی
LBXSATSI	BIOPRO_L	آنزیم کبدی ALT	متغیر کنترلی	کمی پیوسته	نسبی
LBXSASSI	BIOPRO_L	آنزیم کبدی AST	متغیر کنترلی	کمی پیوسته	نسبی
WTMEC2YR	DEMO_L	وزن نمونه‌گیری دو ساله معاینات	وزن‌دهی برای تعمیم	کمی پیوسته	نسبی

الزام الف ۱ : شناسایی فایل‌ها و کلید ادغام

برای ساخت مجموعه داده تحلیلی، ۸ فایل عمومی از دوره ۲۰۲۱ تا ۲۰۲۳ پیمایش NHANES انتخاب شده‌اند. متغیر **SEQN** (شناسه یکتای شرکت‌کننده) کلید مشترک در تمامی فایل‌ها با رابطه یک‌به‌یک است.
فایل اطلاعات جمعیت‌شناختی (DEMO_L) به عنوان فایل پایه در نظر گرفته شده و ۷ فایل دیگر از طریق اتصال چپ (Left Join) روی کلید SEQN به آن متصل می‌شوند.

In [1]:
```
import pandas as pd
import numpy as np
from pathlib import Path

# مسیر پوشه داده
data_dir = Path("../data")

# لیست متغیرهای مورد نیاز از هر هشت فایل
files_vars = {
    "DEMO_L.xpt": ["SEQN", "RIDAGEYR", "RIAGENDR", "WTMEC2YR"],
    "LUX_L.xpt": ["SEQN", "LUXSMED", "LUXCAPM"],
    "CBC_L.xpt": ["SEQN", "LBDNENO", "LBDLYMNO"],
    "BMX_L.xpt": ["SEQN", "BMXBMI"],
    "BPXO_L.xpt": ["SEQN", "BPXOSY1"],
    "GHB_L.xpt": ["SEQN", "LBXGH"],
    "TCHOL_L.xpt": ["SEQN", "LBXTC"],
    "BIOPRO_L.xpt": ["SEQN", "LBXSATSI", "LBXSASSI"]
}

# خواندن فایل پایه و اتصال فایلها به یکدیگر
df_merged = None

for filename, cols in files_vars.items():
    file_path = data_dir / filename
    temp_df = pd.read_sas(file_path, format="xport")[cols]
```

```
    temp_df["SEQN"] = temp_df["SEQN"].astype(int)

    # بررسی یکتا بودن شناسه در هر فایل
    assert temp_df["SEQN"].is_unique, f"Duplicate SEQN found in {filename}"

    if df_merged is None:
        df_merged = temp_df
    else:
        df_merged = pd.merge(df_merged, temp_df, on="SEQN", how="left")

# محاسبه شاخص التهابی بر اساس نوتروفیل و لنفوسیت
df_merged["NLR"] = np.where(
    df_merged["LBDLYMNO"] > 0,
    df_merged["LBDNENO"] / df_merged["LBDLYMNO"],
    np.nan
)

print("\u202bتعداد کل افراد در فایل پایه (DEMO_L):\u202c", len(df_merged))
print("تعداد ستون‌ها پس از ادغام:", df_merged.shape[1])
df_merged.head()
```

```
تعداد کل افراد در فایل پایه (DEMO_L): 11933
تعداد ستون‌ها پس از ادغام: 15
```

```
C:\Users\NOORIE\AppData\Local\Temp\ipykernel_2920\34288443.py:25: Pandas4Warning: Th
e default value of 'encoding' in read_sas is deprecated. In a future version the def
ault will change from None to 'infer', and character columns will be decoded rather
than returned as bytes (XPORT files record no encoding, so 'infer' means 'ISO-8859-
1'). Pass encoding='infer' to adopt the future behavior, or encoding=None to keep th
e current one.
  temp_df = pd.read_sas(file_path, format="xport")[cols]
C:\Users\NOORIE\AppData\Local\Temp\ipykernel_2920\34288443.py:25: Pandas4Warning: Th
e default value of 'encoding' in read_sas is deprecated. In a future version the def
ault will change from None to 'infer', and character columns will be decoded rather
than returned as bytes (XPORT files record no encoding, so 'infer' means 'ISO-8859-
1'). Pass encoding='infer' to adopt the future behavior, or encoding=None to keep th
e current one.
  temp_df = pd.read_sas(file_path, format="xport")[cols]
```

Out[1]:

	SEQN	RIDAGEYR	RIAGENDR	WTMEC2YR	LUXSMED	LUXCAPM	LBDNENO	LBDLYM
0	130378	43.0	1.0	54374.463898	9.5	380.0	2.2	
1	130379	66.0	1.0	34084.721548	3.9	345.0	3.6	
2	130380	44.0	2.0	81196.277992	7.6	255.0	3.3	
3	130381	5.0	2.0	55698.607106	NaN	NaN	NaN	
4	130382	2.0	1.0	36434.146346	NaN	NaN	6.9	

تسک مشترک ۵: ممیزی کیفیت داده و تعریف جمعیت تحلیلی (الزام الف۴)

در این مرحله، ابتدا یکتا بودن شناسه‌ها (SEQN) و مقادیر ناممکن یا کدهای ویژه بررسی شده، سپس داده‌ها طبق معیارهای ورود و خروج به جامعه هدف پژوهش (بزرگسالان ۲۰ سال و بالاتر) محدود می‌شوند و در نهایت وضعیت داده‌های گمشده (Missing) و نحوه برخورد با آن‌ها گزارش می‌گردد.

In [2]:
```
# بررسی رکوردهای تکراری بر اساس شناسه
duplicate_count = df_merged["SEQN"].duplicated().sum()
print(f"تعداد رکوردهای تکراری : {duplicate_count}")

# فیلتر کردن جامعه هدف: بزرگسالان ۲۰ سال و بالاتر
df_adults = df_merged[df_merged["RIDAGEYR"] >= 20].copy()
print(f"تعداد کل افراد پیش از فیلتر سنی: {len(df_merged)}")
print(f"تعداد بزرگسالان (۲۰ سال و بالاتر): {len(df_adults)}")

# جدول ممیزی داده‌های گمشده در جامعه هدف (بزرگسالان ۲۰ سال و بالاتر)
main_vars = [
    "LUXSMED", "NLR", "LUXCAPM", "RIDAGEYR", "RIAGENDR",
    "BMXBMI", "BPXOSY1", "LBXGH", "LBXTC", "LBXSATSI", "LBXSASSI", "WTMEC2YR"
]

audit_table = pd.DataFrame({
    "تعداد معتبر (Valid N)": df_adults[main_vars].notnull().sum(),
    "تعداد گمشده (Missing N)": df_adults[main_vars].isnull().sum(),
    "درصد گمشده (Missing %)": (df_adults[main_vars].isnull().mean() * 100).round(2),
    "کمینه (Min)": df_adults[main_vars].min().round(2),
    "بیشینه (Max)": df_adults[main_vars].max().round(2)
})

audit_table
```

```
تعداد رکوردهای تکراری : 0
تعداد کل افراد پیش از فیلتر سنی: 11933
تعداد بزرگسالان (۲۰ سال و بالاتر): 7809
```

Out[2]:

	تعداد معتبر (Valid N)	تعداد گمشده (Missing N)	درصد گمشده (Missing %)	کمینه (Min)	بیشینه (Max)
LUXSMED	5615	2194	28.10	1.5	75.0
NLR	5758	2051	26.26	0.3	33.5
LUXCAPM	5614	2195	28.11	100.0	400.0
RIDAGEYR	7809	0	0.00	20.0	80.0
RIAGENDR	7809	0	0.00	1.0	2.0
BMXBMI	5970	1839	23.55	11.1	74.8
BPXOSY1	5863	1946	24.92	75.0	232.0
LBXGH	5767	2042	26.15	3.2	17.1
LBXTC	5498	2311	29.59	62.0	438.0
LBXSATSI	5438	2371	30.36	3.0	350.0
LBXSASSI	5426	2383	30.52	6.0	363.0
WTMEC2YR	7809	0	0.00	0.0	227108.3

In [3]:
```
# گزارش مراحل پالایش و تعداد افراد حذف‌شده (الزام الف-۴)
n_total = len(df_merged)
n_adults = len(df_adults)
print(f"\u202b۱. تعداد کل افراد پس از ادغام فایل‌ها: {n_total} نفر\u202c")
print(f"\u202b۲. تعداد افراد حذف‌شده زیر ۲۰ سال: {n_total - n_adults} نفر (باقی‌مانده بزرگسالان: {n_

# بررسی افراد فاقد وزن معاینه پزشکی (WTMEC2YR == 0)
no_mec_count = (df_adults["WTMEC2YR"] == 0).sum()
df_mec = df_adults[df_adults["WTMEC2YR"] > 0].copy()
print(f"\u202b۳. تعداد بزرگسالان فاقد معاینه در مرکز سیار (WTMEC2YR = 0): {no_mec_count} نفر (باقی

# حذف مقادیر گمشده در دو متغیر اصلی پژوهش (LUXSMED و NLR)
df_clean = df_mec.dropna(subset=["LUXSMED", "NLR"]).copy()
dropped_main = len(df_mec) - len(df_clean)
print(f"\u202b۴. تعداد افراد حذف‌شده به دلیل گمشدگی در متغیرهای اصلی (LUXSMED یا NLR): {dropped_ma
print(f"\u202b۵. حجم نمونه تحلیلی نهایی (df_clean): {len(df_clean)} نفر\u202c")
```

```
۱. تعداد کل افراد پس از ادغام فایل‌ها: 11933 نفر
۲. تعداد افراد حذف‌شده زیر ۲۰ سال: 4124 نفر (باقی‌مانده بزرگسالان: 7809 نفر)
۳. تعداد بزرگسالان فاقد معاینه در مرکز سیار (WTMEC2YR = 0): 0 نفر (باقی‌مانده: 7809 نفر)
۴. تعداد افراد حذف‌شده به دلیل گمشدگی در متغیرهای اصلی (LUXSMED یا NLR): 2449 نفر
۵. حجم نمونه تحلیلی نهایی (df_clean): 5360 نفر
```

۱. بررسی رکوردهای تکراری و ناسازگاری‌های منطقی: بررسی ستون شناسه (SEQN) نشان داد هیچ رکورد تکراری در داده وجود ندارد. همچنین پس از اعمال فیلتر سنی، تمامی متغیرها در بازه منطقی قرار دارند (کمینه سن ۲۰ و بیشینه ۸۰ سال است).

۲. بررسی مقادیر غیرممکن و کدهای ویژه: در فایل‌های آزمایشگاهی و الاستوگرافی NHANES، مقادیر نامعتبر به صورت NaN ثبت شده‌اند و کدهای عددی ویژه (مانند 777 یا 999) در متغیرهای کمی منتخب

مشاهده نشد. مقادیر کمینه و بیشینه (مانند سفتی کبد از ۱.۵ تا ۷۵ کیلوپاسکال و NLR از ۰.۳ تا ۳۳.۵) از نظر زیستی و بالینی ممکن هستند، اما نشان‌دهنده چولگی به راست و وجود مقادیر حدی در توزیع می‌باشند.

۳. تصمیم آماری برای برخورد با داده‌های گمشده و دلیل آن:

• **متغیرهای اصلی (LUXSMED و NLR):** از آنجا که هدف اصلی پژوهش بررسی رابطه التهاب سیستمیک (NLR) و سفتی کبد (LUXSMED) است، جایگذاری مقادیر گمشده در این دو متغیر اصلی باعث خطا در بررسی رابطه واقعی بین این دو متغیر می شود؛ بنابراین از روش تحلیل موارد کامل استفاده شد و ۲۴۴۹ نفری که در یکی از این دو متغیر مقدار گمشده داشتند حذف شدند تا حجم نمونه تحلیلی نهایی به ۵۳۶۰ نفر برسد.

• **متغیرهای کمکی و کنترلی:** برای جلوگیری از کاهش غیرضروری حجم نمونه در تحلیل‌های اصلی، ردیف‌هایی که صرفاً در متغیرهای فرعی (مانند کلسترول یا آنزیم‌های کبدی) دارای مقدار گمشده هستند در مجموعه داده نهایی (df_clean) حفظ شدند و تنها در تحلیل‌های چندمتغیره مربوط به همان متغیرها کنار گذاشته می‌شوند.

تسک مشترک ۶: جدول‌های فراوانی و توزیع تجربی

در این مرحله، توزیع تجربی متغیرهای پژوهش در نمونه تحلیلی نهایی (۵۳۶۰ نفر) بررسی می‌شود. ابتدا برای متغیرهای طبقه‌ای (جنسیت و طبقه‌بندی بالینی سفتی کبد) جدول فراوانی و درصد ارائه شده و سپس برای متغیرهای کمی، خلاصه توزیع تجربی شامل چندک‌ها (صدک‌های ۱۰، ۲۵، ۵۰، ۷۵ و ۹۰) و ضریب چولگی گزارش می‌گردد.

In [4]:
```
# ۱. جدول فراوانی و درصد برای متغیر طبقه‌ای جنسیت (RIAGENDR)
gender_map = {1.0: "مرد (Male)", 2.0: "زن (Female)"}
gender_series = df_clean["RIAGENDR"].map(gender_map)

freq_gender = pd.DataFrame({
    "فراوانی (تعداد)": gender_series.value_counts(),
    "درصد (%)": (gender_series.value_counts(normalize=True) * 100).round(2)
})
print("--- جدول فراوانی و درصد جنسیت در نمونه تحلیلی نهایی ---")
display(freq_gender)

# ۲. جدول فراوانی و درصد برای طبقه‌بندی بالینی سفتی کبد (LUXSMED)
fibrosis_bins = [0, 7.0, 8.2, np.inf]
fibrosis_labels = ["طبیعی (< 7.0 kPa)", "ملایم تا متوسط (8.2 - 7.0 kPa)", "فیبروز پیشرفته (>=
fibrosis_cat = pd.cut(df_clean["LUXSMED"], bins=fibrosis_bins, labels=fibrosis_labe

freq_fibrosis = pd.DataFrame({
    "فراوانی (تعداد)": fibrosis_cat.value_counts(),
    "درصد (%)": (fibrosis_cat.value_counts(normalize=True) * 100).round(2)
})
print("\n--- جدول فراوانی وضعیت سفتی کبد (بر اساس آستانه‌های بالینی) ---")
display(freq_fibrosis)

# ۳. خلاصه توزیع تجربی (چندک‌ها و ضریب چولگی) برای متغیرهای کمی
quant_vars = [
    "LUXSMED", "NLR", "LUXCAPM", "RIDAGEYR",
```

```
    "BMXBMI", "BPXOSY1", "LBXGH", "LBXTC", "LBXSATSI", "LBXSASSI"
]

dist_summary = pd.DataFrame({
    "تعداد معتبر (N)": df_clean[quant_vars].notnull().sum(),
    "صدک ۱۰ (P10)": df_clean[quant_vars].quantile(0.10).round(2),
    "چارک اول (Q1)": df_clean[quant_vars].quantile(0.25).round(2),
    "میانه (Median)": df_clean[quant_vars].quantile(0.50).round(2),
    "چارک سوم (Q3)": df_clean[quant_vars].quantile(0.75).round(2),
    "صدک ۹۰ (P90)": df_clean[quant_vars].quantile(0.90).round(2),
    "ضریب چولگی (Skewness)": df_clean[quant_vars].skew().round(2)
})

print("\n--- خلاصه توزیع تجربی متغیرهای کمی ---")
display(dist_summary)
```

--- جدول فراوانی و درصد جنسیت در نمونه تحلیلی نهایی ---

RIAGENDR	فراوانی (تعداد)	درصد (%)
زن (Female)	2930	54.66
مرد (Male)	2430	45.34

--- جدول فراوانی وضعیت سفتی کبد (بر اساس آستانه‌های بالینی) ---

LUXSMED	فراوانی (تعداد)	درصد (%)
طبیعی (< 7.0 kPa)	4307	80.35
فیبروز پیشرفته (>= 8.2 kPa)	705	13.15
ملایم تا متوسط (8.2 - 7.0 kPa)	348	6.49

--- خلاصه توزیع تجربی متغیرهای کمی ---

	تعداد معتبر (N)	صدک ۱۰ (P10)	چارک اول (Q1)	میانه (Median)	چارک سوم (Q3)	صدک ۹۰ (P90)	ضریب چولگی (Skewness)
LUXSMED	5360	3.40	4.1	5.0	6.40	9.10	7.07
NLR	5360	1.15	1.5	2.0	2.66	3.50	2.99
LUXCAPM	5359	186.00	218.0	259.0	308.00	350.00	0.12
RIDAGEYR	5360	29.00	39.0	57.0	68.00	75.00	-0.28
BMXBMI	5326	22.10	24.7	28.4	33.30	39.05	1.15
BPXOSY1	5239	102.80	111.0	121.0	133.00	147.00	0.90
LBXGH	5337	5.00	5.2	5.5	5.90	6.64	3.80
LBXTC	5098	137.00	160.0	186.0	214.75	244.00	0.55
LBXSATSI	5040	10.00	13.0	18.0	25.00	37.00	5.68
LBXSASSI	5029	14.00	17.0	20.0	25.00	31.00	9.52

الگوهای مهم در متغیرهای طبقه‌ای:

• **توازن جنسیتی در نمونه تحلیلی:** بررسی جدول فراوانی جنسیت نشان می‌دهد که ترکیب نمونه تحلیلی نهایی میان زنان و مردان متعادل است (با فراوانی کمی بیشتر برای زنان)، که امکان مقایسه توصیفی معتبر بین دو جنس را در مراحل بعد فراهم می‌کند.

• **توزیع سطوح سفتی کبد:** بخش عمده‌ای از بزرگسالان شرکت‌کننده در بازه طبیعی سفتی کبد (کمتر از ۷ کیلوپاسکال) قرار دارند و تنها بخش کوچکی از جمعیت در رده فیبروز پیشرفته (۸.۲ کیلوپاسکال و بالاتر) جای می‌گیرند که با الگوی شیوع بیماری‌های کبدی در جمعیت عمومی هم‌خوانی دارد.

الگوهای مهم در توزیع تجربی متغیرهای کمی:

• **چولگی شدید به راست در متغیرهای اصلی و آنزیم‌های کبدی:** بررسی چندک‌ها و ضریب چولگی نشان می‌دهد متغیرهای سفتی کبد (LUXSMED)، نسبت نوتروفیل به لنفوسیت (NLR) و آنزیم‌های کبدی (LBXSATSI و LBXSASSI) دارای چولگی مثبت (به سمت راست) هستند؛ به طوری که فاصله صدک ۹۰ تا میانه به مراتب بزرگ‌تر از فاصله میانه تا صدک ۱۰ است. این الگو نشان می‌دهد اکثر افراد جامعه مقادیر پایین و نرمال دارند، اما وجود تعداد کمی از افراد با التهاب یا سفتی کبد بسیار بالا، دنباله توزیع را به سمت راست کشیده است.

• **توزیع متقارن‌تر در متغیرهای عمومی:** متغیرهایی مانند شاخص چربی کبد (LUXCAPM)، کلسترول کل (LBXTC) و فشار خون سیستولیک (BPXOSY1) ضریب چولگی نزدیک به صفر یا ملایمی دارند و چارک‌های اول و سوم آن‌ها با فاصله نسبتاً متوازنی در دو طرف میانه قرار گرفته‌اند.

تسک مشترک ۷: مرکز و پراکندگی و مقایسه خلاصه خام و وزن‌دار (الزام الف۳)

ابتدا شاخص‌های مرکزی (میانگین و میانه) و شاخص‌های پراکندگی (انحراف معیار، چارک‌ها و دامنه بین‌چارکی) برای متغیرهای کمی محاسبه می‌شوند تا معیار مناسب برای هر متغیر بر اساس شکل توزیع

آن مشخص گردد. سپس در راستای الزام ویژه مسیر الف (NHANES)، مقادیر میانگین ساده (بدون وزن) و میانگین وزن‌دار (با اعمال وزن معاینه پزشکی WTMEC2YR) در کنار هم گزارش و مقایسه می‌شوند.

In [5]:
```
# ۱. محاسبه شاخص‌های مرکز و پراکندگی برای متغیرهای کمی
q1 = df_clean[quant_vars].quantile(0.25)
q3 = df_clean[quant_vars].quantile(0.75)

center_disp_table = pd.DataFrame({
    "میانگین (Mean)": df_clean[quant_vars].mean().round(2),
    "انحراف معیار (SD)": df_clean[quant_vars].std().round(2),
    "میانه (Median)": df_clean[quant_vars].median().round(2),
    "چارک اول (Q1)": q1.round(2),
    "چارک سوم (Q3)": q3.round(2),
    "دامنه بین‌چارکی (IQR)": (q3 - q1).round(2)
})

print("--- جدول شاخص‌های مرکز و پراکندگی متغیرهای کمی ---")
display(center_disp_table)

# ۲. مقایسه خلاصه خام (بدون وزن) و وزن‌دار (الزام الف-۳)
def weighted_mean(df, col, weight_col="WTMEC2YR"):
    valid = df[[col, weight_col]].dropna()
    return np.average(valid[col], weights=valid[weight_col])

compare_vars = ["LUXSMED", "NLR", "LUXCAPM", "RIDAGEYR", "BMXBMI", "BPXOSY1"]

weighted_comp_table = pd.DataFrame({
    "میانگین خام (Unweighted Mean)": [df_clean[c].mean() for c in compare_vars],
    "میانگین وزن‌دار (Weighted Mean)": [weighted_mean(df_clean, c) for c in compare_vars
}, index=compare_vars).round(2)

weighted_comp_table["تفاوت (وزن‌دار - خام)"] = (
    weighted_comp_table["میانگین وزن‌دار (Weighted Mean)"] -
    weighted_comp_table["میانگین خام (Unweighted Mean)"]
).round(2)

# محاسبه نسبت خام و وزن‌دار برای فیبروز پیشرفته (>= 8.2 kPa)
df_clean["adv_fibrosis"] = (df_clean["LUXSMED"] >= 8.2).astype(int)
unw_prop = df_clean["adv_fibrosis"].mean() * 100
w_prop = weighted_mean(df_clean, "adv_fibrosis") * 100

print("\n--- جدول مقایسه میانگین خام و وزن‌دار (با اعمال وزن WTMEC2YR) ---")
display(weighted_comp_table)
print(f"\u202bدرصد فیبروز پیشرفته (>= 8.2 kPa) - خام: {unw_prop:.2f}% | وزن‌دار: {w_prop:.2
```

--- جدول شاخص‌های مرکز و پراکندگی متغیرهای کمی ---

	میانگین (Mean)	انحراف معیار (SD)	میانه (Median)	چارک اول (Q1)	چارک سوم (Q3)	دامنه بین‌چارکی (IQR)
LUXSMED	6.41	6.60	5.0	4.1	6.40	2.30
NLR	2.22	1.16	2.0	1.5	2.66	1.16
LUXCAPM	263.41	63.27	259.0	218.0	308.00	90.00
RIDAGEYR	53.79	16.93	57.0	39.0	68.00	29.00
BMXBMI	29.66	7.07	28.4	24.7	33.30	8.60
BPXOSY1	123.03	18.25	121.0	111.0	133.00	22.00
LBXGH	5.78	1.10	5.5	5.2	5.90	0.70
LBXTC	188.83	42.33	186.0	160.0	214.75	54.75
LBXSATSI	22.00	16.70	18.0	13.0	25.00	12.00
LBXSASSI	22.58	13.23	20.0	17.0	25.00	8.00

--- جدول مقایسه میانگین خام و وزن‌دار (با اعمال وزن WTMEC2YR) ---

	میانگین خام (Unweighted Mean)	میانگین وزن‌دار (Weighted Mean)	تفاوت (وزن‌دار - خام)
LUXSMED	6.41	6.28	-0.13
NLR	2.22	2.18	-0.04
LUXCAPM	263.41	263.89	0.48
RIDAGEYR	53.79	48.79	-5.00
BMXBMI	29.66	29.54	-0.12
BPXOSY1	123.03	121.18	-1.85

درصد فیبروز پیشرفته (>= 8.2 kPa) - خام: 13.15% | وزن‌دار: 12.31%

۱. انتخاب معیار مناسب مرکز و پراکندگی بر اساس شکل توزیع:

• **متغیرهای دارای چولگی شدید (مانند LUXSMED، NLR و آنزیم‌های کبدی):** در این متغیرها، میانگین به طور محسوسی بزرگ‌تر از میانه است و انحراف معیار نیز تحت تأثیر مقادیر حدی (پرت) در دنباله راست توزیع، بزرگ شده است. از آنجا که میانگین و انحراف معیار نسبت به مشاهدات پرت بسیار حساس هستند، برای توصیف مرکز و پراکندگی این متغیرها، **میانه (Median)** و **دامنه بین‌چارکی (IQR)** معیارهای مقاوم‌تر و مناسب‌تری محسوب می‌شوند.

• **متغیرهای دارای توزیع نزدیک به متقارن (مانند LUXCAPM، کلسترول و فشار خون):** در این متغیرها، مقادیر میانگین و میانه به یکدیگر بسیار نزدیک هستند و چولگی شدیدی وجود ندارد؛ بنابراین گزارش **میانگین (Mean)** و **انحراف معیار (SD)** در کنار میانه و دامنه بین چارکی کاملاً گویا و مناسب است.

۲. مقایسه خلاصه خام و وزن‌دار (الزام الف-۳ و نقش طرح نمونه‌گیری):

• در پیمایش NHANES، به دلیل بیش‌نمونه‌گیری هدفمند از برخی زیرگروه‌ها (مانند سالمندان یا اقلیت‌های نژادی)، ترکیب افراد حاضر در فایل داده با ترکیب واقعی جمعیت ایالات متحده یکسان نیست. برای مثال، میانگین سنی در نمونه خام بالاتر از میانگین سنی وزن‌دار است، زیرا افراد مسن‌تر با احتمال

بیشتری وارد نمونه شده‌اند.
• با اعمال وزن معاینه پزشکی (WTMEC2YR)، اثر این بیش‌نمونه‌گیری تعدیل شده و برآوردها (مانند میانگین سن، سفتی کبد، NLR و درصد شیوع فیبروز پیشرفته) به مقادیر واقعی جامعه بزرگسالان ۲۰ سال و بالاتر در ایالات متحده نزدیک می‌شوند.

تسک مشترک ۸: مصورسازی درست متغیرها

چهار نمودار استاندارد متناسب با نوع و مقیاس اندازه‌گیری متغیرها روی نمونه تحلیلی نهایی (۵۳۶۰ نفر) رسم می‌شود. در طراحی این نمودارها، کامل بودن عنوان، برچسب محورها، واحد اندازه‌گیری و عدم برش گمراه‌کننده محورها رعایت شده است:
۱. **نمودار هیستوگرام (Histogram):** برای نمایش شکل توزیع و چولگی متغیر کمی پیوسته سفتی کبد (LUXSMED).
۲. **نمودار جعبه‌ای (Boxplot):** برای نمایش میانه، چارک‌ها (Q1 و Q3) و دامنه بین‌چارکی (IQR) متغیر کمی شاخص چربی کبد (LUXCAPM) به تفکیک جنسیت.
۳. **نمودار میله‌ای (Bar Chart):** برای نمایش فراوانی و درصد متغیر طبقه‌ای وضعیت بالینی سفتی کبد.
۴. **نمودار پراکنش (Scatter Plot):** برای نمایش توزیع مشترک دو متغیر کمی اصلی پژوهش (NLR و سفتی کبد).

In [6]:
```
import matplotlib.pyplot as plt
import seaborn as sns

# تعیین قالب و پس زمینه نمودارها
sns.set_theme(style="whitegrid")

fig, axes = plt.subplots(2, 2, figsize=(15, 11))
plt.subplots_adjust(hspace=0.35, wspace=0.25)

# ۱. نمودار اول: هیستوگرام توزیع سفتی کبد (متغیر کمی پیوسته)
ax1 = axes[0, 0]
sns.histplot(df_clean["LUXSMED"], bins=40, kde=True, color="#2b5c8f", ax=ax1)
ax1.axvline(df_clean["LUXSMED"].mean(), color="#d95f02", linestyle="--", linewidth=
ax1.axvline(df_clean["LUXSMED"].median(), color="#1b9e77", linestyle="-", linewidth
ax1.set_title("1. Distribution of Liver Stiffness (LUXSMED)", fontsize=12, fontweig
ax1.set_xlabel("Liver Stiffness Median (kPa)", fontsize=11)
ax1.set_ylabel("Number of Participants (Count)", fontsize=11)
ax1.legend()

# ۲. دوم: نمودار جعبه‌ای شاخص چربی کبد بر حسب جنسیت (نمایش مرکز، پراکندگی و نقاط پرت)
ax2 = axes[0, 1]
df_clean["Gender_Label"] = df_clean["RIAGENDR"].map({1.0: "Male", 2.0: "Female"})
sns.boxplot(
    data=df_clean, x="Gender_Label", y="LUXCAPM",
    hue="Gender_Label", palette=["#4a90e2", "#e26a6a"], legend=False, width=0.45, a
)
ax2.set_title("2. Boxplot of Liver Steatosis (LUXCAPM) by Gender", fontsize=12, fon
ax2.set_xlabel("Gender", fontsize=11)
ax2.set_ylabel("Controlled Attenuation Parameter (dB/m)", fontsize=11)
```

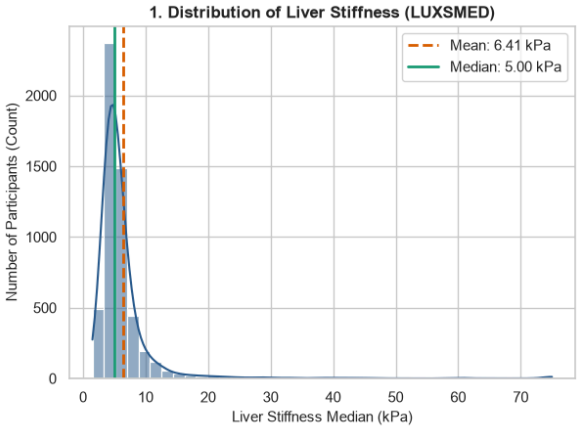
```python
# ۳. نمودار سوم: نمودار میله‌ای طبقه‌بندی بالینی سفتی کبد (متغیر طبقه‌ای ترتیبی)
ax3 = axes[1, 0]
fib_bins = [0, 7.0, 8.2, np.inf]
fib_labels = ["Normal\n(< 7.0 kPa)", "Mild-Moderate\n(7.0 - 8.2 kPa)", "Advanced Fi
fib_series = pd.cut(df_clean["LUXSMED"], bins=fib_bins, labels=fib_labels, right=Fa
fib_counts = fib_series.value_counts().reindex(fib_labels)
fib_pcts = (fib_counts / len(df_clean)) * 100

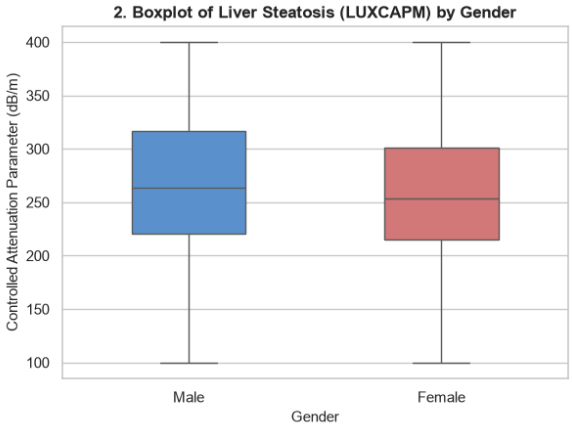
bars = ax3.bar(fib_labels, fib_counts, color=["#66c2a5", "#fc8d62", "#8da0cb"], wid
ax3.set_title("3. Frequency of Clinical Liver Stiffness Stages", fontsize=12, fontw
ax3.set_xlabel("Clinical Stage (kPa Thresholds)", fontsize=11)
ax3.set_ylabel("Number of Participants (Count)", fontsize=11)
ax3.set_ylim(0, max(fib_counts) * 1.15)

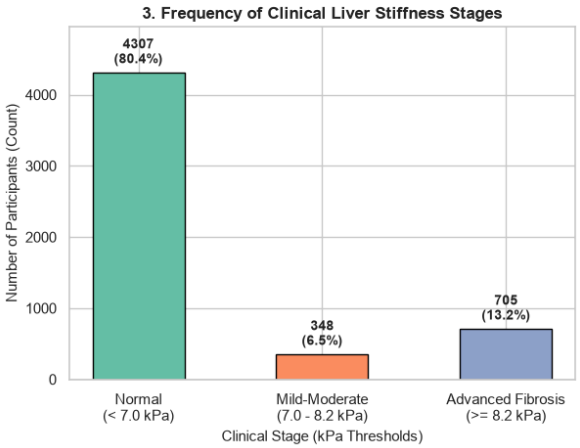
for bar, pct in zip(bars, fib_pcts):
    height = bar.get_height()
    ax3.text(bar.get_x() + bar.get_width() / 2., height + 80, f"{int(height)}\n({pc

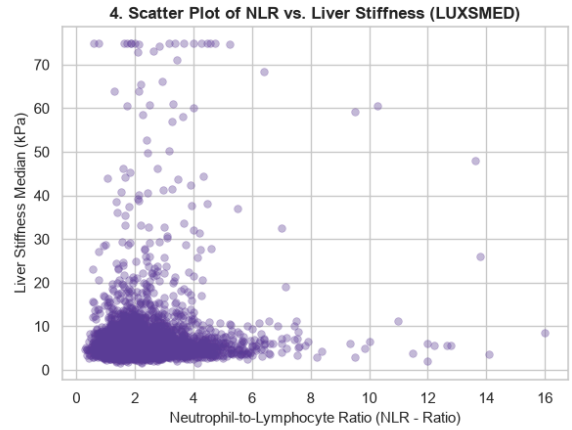
# ۴. نمودار چهارم: نمودار پراکنش دو متغیر کمی اصلی (NLR و سفتی کبد)
ax4 = axes[1, 1]
sns.scatterplot(
    data=df_clean, x="NLR", y="LUXSMED",
    alpha=0.35, color="#5e3c99", edgecolor=None, s=30, ax=ax4
)
ax4.set_title("4. Scatter Plot of NLR vs. Liver Stiffness (LUXSMED)", fontsize=12,
ax4.set_xlabel("Neutrophil-to-Lymphocyte Ratio (NLR - Ratio)", fontsize=11)
ax4.set_ylabel("Liver Stiffness Median (kPa)", fontsize=11)

# ذخیره مستقیم در پوشه figures موجود
plt.savefig("../figures/phase1_visualizations.png", dpi=300, bbox_inches="tight")
plt.show()
```









بررسی و تفسیر یافته‌های نمودارهای چهارگانه:

۱. توزیع فراوانی سفتی کبد (هیستوگرام LUXSMED): نمایش گرافیکی این متغیر پیوسته بیانگر عدم تقارن و چولگی مثبت (به سمت راست) در داده‌ها است. در حالی که بخش عمده شرکت‌کنندگان دارای مقادیر سفتی کبد در محدوده طبیعی (حوالی ۳ تا ۷ کیلوپاسکال) هستند، وجود مقادیر حدی تا سقف ۷۵ کیلوپاسکال موجب کشیده شدن دنباله راست توزیع شده است؛ به همین دلیل، میانگین (۶.۴۱ کیلوپاسکال) بالاتر از میانه (۵.۰۰ کیلوپاسکال) قرار گرفته است.

۲. مقایسه شاخص چربی کبد بر حسب جنسیت (نمودار جعبه‌ای LUXCAPM): بررسی نمودار جعبه‌ای نشان می‌دهد که پراکندگی و شکل کلی توزیع شاخص چربی کبد در هر دو گروه مردان و زنان تقریباً متقارن است؛ با این حال، میانه و چارک‌های اول و سوم در گروه مردان در سطح بالاتری نسبت به زنان قرار دارند. همچنین تمام بازه مقادیر (از ۱۰۰ تا ۴۰۰ دسی‌بل بر متر) به صورت کامل پوشش داده شده است.

۳. فراوانی مراحل بالینی سفتی کبد (نمودار میله‌ای): برای نمایش این متغیر طبقه‌ای ترتیبی، از نمودار میله‌ای با مبدأ صفر در محور عمودی استفاده شده است. بر اساس نتایج، ۸۰.۴٪ از افراد نمونه (۴۳۰۷ نفر) در محدوده طبیعی، ۶.۵٪ (۳۴۸ نفر) در مرحله فیبروز ملایم تا متوسط و ۱۳.۲٪ (۷۰۵ نفر) در مرحله فیبروز پیشرفته دسته‌بندی می‌شوند.

۴. توزیع مشترک التهاب سیستمیک و سفتی کبد (نمودار پراکنش NLR و LUXSMED): این نمودار توزیع دو متغیر کمی اصلی پژوهش را در کنار هم نشان می‌دهد. تراکم اصلی مشاهدات در مقادیر پایین هر دو متغیر (NLR کمتر از ۵ و سفتی کبد کمتر از ۱۰ کیلوپاسکال) قرار دارد و نقاط پراکنده در بخش بالایی و راستی نمودار، افراد دارای التهاب سیستمیک بالا یا سفتی کبد شدید را نشان می‌دهند.

تسک مشترک ۹: مقایسه توصیفی اولیه

در این مرحله، شاخص‌های مرکزی و پراکندگی متغیرهای کلیدی پژوهش در زیرگروه‌های مختلف نمونه تحلیلی (۵۳۶۰ نفر) با یکدیگر مقایسه می‌شوند. ابتدا مقایسه بر اساس **جنسیت** انجام می شود و سپس ویژگی‌های التهابی و متابولیک شرکت‌کنندگان در سه زیرگروه **وضعیت بالینی سفتی کبد** (طبیعی، ملایم تا متوسط، و فیبروز پیشرفته) بررسی می‌گردد.

In [7]:
```python
# ۱. مقایسه توصیفی متغیرهای اصلی به تفکیک جنسیت
df_clean["جنسیت"] = df_clean["RIAGENDR"].map({1.0: "مرد (Male)", 2.0: "زن (Female)"})

sub_vars = ["LUXSMED", "NLR", "LUXCAPM", "BMXBMI", "LBXGH", "LBXSATSI"]

def group_summary(df, group_col, vars_list):
    records = []
    for var in vars_list:
        for grp, sub_df in df.groupby(group_col, observed=False):
            s = sub_df[var].dropna()
            q1, q3 = s.quantile(0.25), s.quantile(0.75)
            records.append({
                "متغیر": var,
                "زیرگروه": grp,
                "تعداد (N)": len(s),
                "میانگین (Mean)": round(s.mean(), 2),
                "انحراف معیار (SD)": round(s.std(), 2),
                "میانه (Median)": round(s.median(), 2),
                "دامنه بین‌چارکی (IQR)": round(q3 - q1, 2)
            })
    return pd.DataFrame(records).set_index(["زیرگروه" ,"متغیر"])

gender_comparison = group_summary(df_clean, "جنسیت", sub_vars)
print("--- ۱. جدول مقایسه توصیفی متغیرهای کلیدی به تفکیک جنسیت ---")
display(gender_comparison)

# ۲. مقایسه توصیفی شاخص‌های التهابی و متابولیک در مراحل مختلف سفتی کبد
fib_bins = [0, 7.0, 8.2, np.inf]
fib_labels = ["۱. طبیعی (< 7.0 kPa)", "۲. ملایم تا متوسط (8.2 - 7.0 kPa)", "۳. فیبروز پیشرفته
df_clean["مرحله سفتی کبد"] = pd.cut(df_clean["LUXSMED"], bins=fib_bins, labels=fib_labe

stage_vars = ["NLR", "LUXCAPM", "RIDAGEYR", "BMXBMI", "LBXGH", "LBXSATSI", "LBXSASS
stage_comparison = group_summary(df_clean, "مرحله سفتی کبد", stage_vars)

print("\n--- ۲. جدول مقایسه توصیفی شاخص‌ها در زیرگروه‌های بالینی سفتی کبد ---")
display(stage_comparison)
```

--- ۱. جدول مقایسه توصیفی متغیرهای کلیدی به تفکیک جنسیت ---

متغیر	زیرگروه	تعداد (N)	میانگین (Mean)	انحراف معیار (SD)	میانه (Median)	دامنه بین‌چارکی (IQR)
LUXSMED	**زن (Female)**	2930	5.91	4.98	4.90	2.20
	مرد (Male)	2430	7.01	8.09	5.20	2.40
NLR	**زن (Female)**	2930	2.13	1.00	1.94	1.06
	مرد (Male)	2430	2.33	1.32	2.04	1.27
LUXCAPM	**زن (Female)**	2929	259.11	60.88	254.00	86.00
	مرد (Male)	2430	268.58	65.67	264.00	96.00
BMXBMI	**زن (Female)**	2913	30.07	7.69	28.60	10.00
	مرد (Male)	2413	29.18	6.22	28.00	7.40
LBXGH	**زن (Female)**	2915	5.75	1.07	5.50	0.60
	مرد (Male)	2422	5.80	1.14	5.50	0.70
LBXSATSI	**زن (Female)**	2741	18.88	13.93	16.00	9.00
	مرد (Male)	2299	25.71	18.85	21.00	14.00

--- جدول مقایسه توصیفی شاخص‌ها در زیرگروه‌های بالینی سفتی کبد ۲. ---

متغیر	زیرگروه	تعداد (N)	میانگین (Mean)	انحراف معیار (SD)	میانه (Median)	دامنه بین‌چارکی (IQR)
NLR	۱. طبیعی (< 7.0 kPa)	4307	2.18	1.11	1.95	1.15
	۲. ملایم تا متوسط (8.2 - 7.0 kPa)	348	2.25	1.09	2.00	1.22
	۳. فیبروز پیشرفته (>= 8.2 kPa)	705	2.42	1.44	2.14	1.18
LUXCAPM	۱. طبیعی (< 7.0 kPa)	4306	253.69	58.77	249.50	79.00
	۲. ملایم تا متوسط (8.2 - 7.0 kPa)	348	289.09	63.65	294.50	92.25
	۳. فیبروز پیشرفته (>= 8.2 kPa)	705	310.10	65.27	320.00	94.00
RIDAGEYR	۱. طبیعی (< 7.0 kPa)	4307	53.02	17.23	56.00	29.00
	۲. ملایم تا متوسط (8.2 - 7.0 kPa)	348	56.54	15.84	59.50	24.00
	۳. فیبروز پیشرفته (>= 8.2 kPa)	705	57.16	14.98	60.00	22.00
BMXBMI	۱. طبیعی (< 7.0 kPa)	4282	28.46	6.01	27.50	7.60
	۲. ملایم تا متوسط (8.2 - 7.0 kPa)	345	32.53	7.32	31.30	10.30
	۳. فیبروز پیشرفته (>= 8.2 kPa)	699	35.64	9.22	34.50	12.00
LBXGH	۱. طبیعی (< 7.0 kPa)	4290	5.67	0.97	5.50	0.60
	۲. ملایم تا متوسط (8.2 - 7.0 kPa)	347	6.03	1.28	5.70	0.85
	۳. فیبروز پیشرفته (>= 8.2 kPa)	700	6.27	1.52	5.80	1.20
LBXSATSI	۱. طبیعی (< 7.0 kPa)	4059	20.57	13.67	17.00	11.00
	۲. ملایم تا متوسط (8.2 - 7.0 kPa)	326	25.17	19.46	20.00	17.00
	۳. فیبروز پیشرفته (>= 8.2 kPa)	655	29.25	27.06	23.00	16.00

متغیر	زیرگروه	تعداد (N)	میانگین (Mean)	انحراف معیار (SD)	میانه (Median)	دامنه بین‌چارکی (IQR)
LBXSASSI	۱. طبیعی (< 7.0 kPa)	4050	21.46	9.34	20.00	8.00
	۲. ملایم تا متوسط (7.0 - 8.2 kPa)	324	24.17	16.30	21.00	10.00
	۳. فیبروز پیشرفته (>= 8.2 kPa)	655	28.74	25.05	23.00	12.00

تحلیل و تفسیر مقایسه‌های توصیفی بین زیرگروه‌ها:

• **تفاوت‌های مشاهده‌شده بر حسب جنسیت:** بررسی جدول اول نشان می‌دهد که مردان در مقایسه با زنان دارای مقادیر بالاتری در شاخص‌های کبدی (میانگین و میانه سفتی کبد LUXSMED، شاخص چربی کبد LUXCAPM و آنزیم کبدی ALT/LBXSATSI) و همچنین سطح بالاتری از نسبت نوتروفیل به لنفوسیت (NLR) هستند؛ در حالی که شاخص توده بدنی (BMXBMI) و هموگلوبین گلیکوزیله (LBXGH) در دو جنس بسیار به هم نزدیک است.

• **تفاوت‌های مشاهده‌شده در زیرگروه‌های بالینی سفتی کبد:** مقایسه سه گروه بالینی نشان می‌دهد که با حرکت از گروه «طبیعی» به سمت «فیبروز پیشرفته»، میانگین و میانه شاخص التهابی **NLR** روند افزایشی دارد. همچنین افراد حاضر در گروه فیبروز پیشرفته، به طور محسوسی دارای میانگین و میانه بالاتری در شاخص چربی کبد (LUXCAPM)، شاخص توده بدنی (BMXBMI)، سن (RIDAGEYR)، قند خون سه‌ماهه (LBXGH) و آنزیم‌های کبدی هستند.

• **محدودیت توصیفی بودن مقایسه‌ها (عدم استنباط علّی):** تفاوت‌های مشاهده‌شده در این جداول صرفاً توصیفی هستند و به تنهایی اثبات‌کننده رابطه علّی یا معناداری آماری در جامعه هدف نیستند؛ زیرا اولاً هنوز آزمون فرضیه رسمی و برآورد فاصله اطمینان انجام نشده است و ثانیاً متغیرهای مخدوش‌گر مهمی مانند سن، شاخص توده بدنی و وضعیت دیابت می‌توانند به طور هم‌زمان بر سطح التهاب (NLR) و سفتی کبد اثر بگذارند.

تسک مشترک ۱۰: نهایی کردن سؤال آماری

سؤال نهایی پروژه: با توجه به ممیزی کیفیت داده و بررسی توزیع متغیرها، سؤال اصلی پروژه به این صورت است: «آیا در بزرگسالان ۲۰ سال و بالاتر ایالات متحده (دوره ۲۰۲۱ تا ۲۰۲۳ پیمایش NHANES)، بین نسبت نوتروفیل به لنفوسیت (NLR) و شاخص کمی سفتی کبد (LUXSMED بر حسب کیلوپاسکال) ارتباط آماری وجود دارد؟ و آیا این ارتباط پس از کنترل سن (RIDAGEYR)، جنسیت (RIAGENDR)، شاخص توده بدنی (BMXBMI)، میزان چربی کبد (LUXCAPM)، قند خون سه‌ماهه (LBXGH)، فشار خون سیستولیک (BPXOSY1)، کلسترول تام (LBXTC) و آنزیم‌های کبدی (LBXSATSI و LBXSASSI) همچنان برقرار می‌ماند؟»

کفایت حجم نمونه و کیفیت داده: پس از اعمال معیارهای ورود به مطالعه (بزرگسالان ۲۰ سال به بالا و دارای وزن معاینه معتبر) و حذف موارد گمشده در دو متغیر اصلی، ۵۳۶۰ شرکت‌کننده مستقل باقی مانده‌اند که حجم نمونه بسیار مناسبی را برای برآوردهای استنباطی و مدل‌سازی رگرسیونی فراهم می‌کند.

شواهد توصیفی هم‌راستا با سؤال: مقایسه‌های توصیفی در تسک ۹ نشان داد که با پیشرفت وضعیت بالینی از کبد طبیعی (کمتر از ۷ کیلوپاسکال) به سمت فیبروز پیشرفته (۸.۲ کیلوپاسکال و بالاتر)، میانگین

شاخص التهابی NLR از ۲.۱۸ به ۲.۴۲ و میانه آن از ۱.۹۵ به ۲.۱۴ افزایش می‌یابد. همچنین تفاوت مشهود زیرگروه‌ها در متغیرهایی مانند سن، شاخص توده بدنی و چربی کبد، ضرورت کنترل این متغیرهای مخدوش‌گر را تأیید می‌کند.
